



Etapas 3 - Tratamiento ETL con SSIS

Dinámica empresarial y supervivencia de empresas

Estudiantes:

Ingrid Katherin Caicedo Rodríguez

Código: 561222108

Juan José Ibáñez Martínez

Código: 561222129

Gestor del Conocimiento:

Edison Gustavo Canon Varela

CADI: Minería de datos

Grupo: 901T

Universidad de Cundinamarca - Extensión Chía

Facultad de Ingeniería

Ingeniería de Sistemas y Computación

2026

Contenido

1. Introducción.....	2
2. Diagnóstico inicial y reglas de tratamiento	3
3. Diseño del Control Flow y del Data Flow	3
3.1. Control Flow:	3
3.2. Data Flow (Cargar Staging):	4
3.3. Data Flow (Transformar y Cargar):.....	4
4. Paso a paso de configuración de componentes	5
5. Evidencias de ejecución de las 3 iteraciones	9
6. Manejo de errores y tratamiento de revisión	10
7. Comparación de resultados.....	10
8. Evidencia de no generación de duplicados.....	11
9. Implementación en Flask.....	11
10. Gestión en GitHub.....	12

1. Introducción

En este informe se documentará la etapa 3 del proyecto en la cual se implemento un proceso ETL mediante SQL Server Integration Services (SSIS) para tratar los problemas de calidad de datos identificados en la etapa 2 sobre el conjunto consolidado de información financiera empresarial (SIREM – Superintendencia de sociedades).

Se ejecutaron 3 iteraciones de tratamiento, documentación en cada una de las reglas aplicadas, los ajustes realizados y los resultados obtenidos, garantizando la trazabilidad y no duplicación de los datos.

2. Diagnóstico inicial y reglas de tratamiento


<i>Problema identificado en Etapa 2</i>	<i>Campo afectado</i>	<i>Acción de tratamiento</i>	<i>Justificación</i>
<i>Valores vacíos</i>	Activo_Total, Pasivo_Total, Patrimonio_Total, Tamano_Empresa	Conservar como NULL, no imputar	Evitar inventar información financiera
<i>Razones infinitas (división por cero)</i>	Razon_Endeudamiento	Limpiar y enviar a revisión	Un valor infinito no es interpretable analíticamente
<i>Diferencia contable (Activo ≠ Pasivo + Patrimonio)</i>	Activo_Total, Pasivo_Total, Patrimonio_Total	Marcar y enviar a revisión (tolerancia 1%)	Preservar el dato sin alterar cifras reales sin evidencia
<i>Formatos de fecha mixtos</i>	fecha_corte	Conversión a tipo fecha	Permitir comparaciones temporales
<i>Codificación de texto (tildes/ñ mal leídas)</i>	Tamano_Empresa	Ajuste de página de códigos a UTF-8	Preservar la integridad de los caracteres especiales

Vista de datos									
Datos de ejemplo (como máximo las 200 primeras filas)									
nit	fecha_corte	Patrimonio_T...	Activo_Total	Pasivo_Total	Tamano_Em...	Razon_Ende...	Insolvencia_T...	Ano_Corte	Fue
800000090	2019-12-31	1334869.0					No	2019	SIR
800000268	2019-12-31	1041906.0					No	2019	SIR
800000276	2018-12-31		161623087.0		Grande		No	2018	SIR
800000276	2019-12-31		161623087.0		Grande		No	2019	SIR
800000296	2020-12-31	3621198.0	12215755.0	13991260.0	Mediana	1.14534549...	No	2020	SIR
800000313	2021-12-31		4397438.0		Pequeña		No	2021	SIR
800000393	2019-12-31	1421779.0					No	2019	SIR
800000439	2020-12-31	3049388.0					No	2020	SIR
800000457	2018-12-31		7032359.0		Mediana		No	2018	SIR
800000513	2019-12-31	6412838.0					No	2019	SIR
800000946	2016-12-31			248425658.0			No	2016	SIR
800000946	2018-12-31	159285415.0	336494111.0		Grande		No	2018	SIR
800001020	2016-12-31	20193161.0					No	2016	SIR
800001020	2019-12-31			6618968.0			No	2019	SIR
800001047	2016-12-31			1390757.0			No	2016	SIR
800001047	2020-12-31		4845351.0		Pequeña		No	2020	SIR
800001075	2019-12-31		40088975.0		Grande		No	2019	SIR

3. Diseño del Control Flow y del Data Flow


3.1. Control Flow:

El paquete inicia con una tarea “SQL – Limpiar Staging” (TRUNCATE de las 3 tablas), seguida de dos tareas de flujo de datos: "DFT - Cargar Staging" (carga el CSV crudo) y "DFT - Transformar y Cargar" (aplica todas las reglas de limpieza y separa los datos aceptados de los enviados a revisión).




3.2. Data Flow (Cargar Staging):

Lee el archivo CSV, convierte los tipos de texto a Unicode, y carga en la tabla Staging_SIREM sin modificar los valores originales.




3.3. Data Flow (Transformar y Cargar):

Aplica limpieza de vacíos, detección de infinitos, recalcule de variables, conversión de tipos, división condicional (buena vs. revisión), ordenamiento con eliminación de duplicados, búsqueda (Lookup) anti-duplicados, y carga final a Datos_Tratados y Registros_Revision.




4. Paso a paso de configuración de componentes


- **Flat File Source / Conexión CSV:** Configuración del administrador de conexiones, incluyendo la corrección de codificación a UTF-8.




- **Data Conversion (Conversión de datos):** conversión de texto a tipos Unicode y numéricos.




- **Derived Column (Columna derivada):** Reglas de limpieza de vacíos y detección de infinitos.




- **Conditional Split (División condicional):** Separación de registros según Flag_Infinito y diferencia contable.



- **Sort (Ordenar):** Eliminación de duplicados por clave nit + fecha_corte.



- **Lookup (Búsqueda):** Verificación de existencia previa para evitar duplicados al reejecutar.



5. Evidencias de ejecución de las 3 iteraciones

Iteración 1:


108 %

Results Messages

1	total_tratados_iter2	25164
1	total_revision_iter2	266
1	total_tratados_iter1	76020
1	total_revision_iter1	270

	nit	fecha_corte_original	valor_original_json	motivo_revision	Iteracion
1	800000296	2020-12-31	activo=12215755.0 pasivo=13991260.0 patrimonio=3...	Diferencia contable: Activo distinto de Pasivo m...	2
2	800008116	2020-12-31	activo=24199120.0 pasivo=22854641.0 patrimonio=7...	Diferencia contable: Activo distinto de Pasivo m...	2
3	800012310	2020-12-31	activo=1082180.0 pasivo=631075.0 patrimonio=4397...	Diferencia contable: Activo distinto de Pasivo m...	2

Iteración 2:



Iteración 3 (prueba de no-duplicados):

Se ejecutó el paquete dos veces consecutivas sin modificar ningún componente; en ambas ejecuciones, Datos_Tratados mantuvo 25.164 registros, confirmando que el componente Lookup previene la duplicación.


Results Messages

1	(No column name)	25164
---	------------------	-------

1	total_despues_de_repetir	25164
---	--------------------------	-------

6. Manejo de errores y tratamiento de revisión

Describe brevemente los errores técnicos resueltos durante la construcción (tipos de datos incompatibles Unicode/non-Unicode, columnas con metadata desactualizada, orden de evaluación en Derived Column) como evidencia del proceso iterativo de depuración.



Para los registros enviados a revisión:

Results					
nit	fecha_corte	Activo_Total	Pasivo_Total	Razon_Endeudamiento	
1	900328533	2016-12-31	0.0	9180142.0	inf

nit	fecha_corte_original	valor_original_json	motivo_revision	Iteration
1	900328533	2016-12-31	NULL	Razon de endeudamiento no interpretable 2

7. Comparación de resultados

Dimensión	Antes (Staging)	Después (Datos_Tratados)
Compleitud (Activo_Total)	62.84% nulos	63.51% nulos (esperado, se filtraron 266 registros)
Validez (razones infinitas)	2 de 1.141	0 de 875
Exactitud (diferencia contable)	No se detectaba	264 registros marcados y separados

Results Messages				
Momento	Total_Registros	Nulos_Activo	Pct_Nulos_Activo	
1 ANTES (Staging)	25430	15981	62.8430987023201	
2 DESPUÉS (Datos_Tratados)	25164	15981	63.5073915116834	

Momento	Total_Con_Razon	Razones_Infinitas	
1 ANTES (Staging)	1141	2	
2 DESPUÉS (Datos_Tratados)	875	0	

Total_Marcados_Diferencia_Contable
1 264

nit	fecha_corte	Activo_Total	Pasivo_Total	Patrimonio_Total	Tamano_Empresa	Razon_Endeudamiento
-----	-------------	--------------	--------------	------------------	----------------	---------------------

8. Evidencia de no generación de duplicados

Se verificó que reejecutar el mismo lote no genera registros duplicados: se corrió el paquete dos veces consecutivas sin modificar ningún componente, y en ambas ejecuciones la tabla Datos_Tratados mantuvo 25.164 registros.

9. Implementación en Flask

Bitácora CADI

Inicio / Portada

Navegación del Proyecto

- Etapa 1: Definición
- Etapa 2: Calidad de Datos**
 - 1. Perfilamiento y métricas
 - 2. Tratamiento
 - 3. Homologación
- Etapa 3: Tratamiento ETL con SSIS

Resultados del ETL

Tratamiento ETL con SSIS aplicado a los problemas de calidad detectados en la Etapa 2.

Introducción

Se implementó un proceso ETL (Extract, Transform, Load) con SQL Server Integration Services (SSIS) para tratar los problemas de calidad detectados en la Etapa 2. El paquete SSIS recibe el dataset consolidado, aplica las reglas de limpieza, validación y homologación definidas en las fases anteriores, y escribe el resultado en SQL Server separando los registros aceptados de los que requieren revisión. A continuación se presentan las iteraciones ejecutadas durante la puesta a punto del paquete.

Iteraciones del proceso ETL

Iteración	Ajuste aplicado	Registros recibidos	Aceptados	A revisión
Iteración 1	Limpieza básica de vacíos + detección de infinitos	25.430	25.428	2
Iteración 2	+ Recalcular Tamano_Empresa + detección de diferencia contable	25.430	25.164	266
Iteración 3	+ Componente Lookup anti-duplicados	25.430	25.164	266

Se verificó que reejecutar el mismo lote no genera registros duplicados: en dos ejecuciones consecutivas, Datos_Tratados mantuvo 25.164 registros.

[Descargar Informe Técnico \(PDF\)](#)

Video

10. Gestión en GitHub

github.com/layrun/Dinamica-Empresarial/branches

BranchUpdated

main2 weeks ago

inglésespañolDefault

Your branches

Branch	Updated	Check status	Behind	Ahead	Pull request
etapa3	1 hour ago		0	2	
ingrid	2 weeks ago		1	0	

Active branches

Branch	Updated	Check status	Behind	Ahead	Pull request
etapa3	1 hour ago		0	2	
ingrid	2 weeks ago		1	0	
etapa2	3 weeks ago		10	0	#11
Etapa1	last month		60	0	#8
Juanjo	last month		73	0	

© 2026 GitHub, Inc. Terms Privacy Security Status Community Docs Contact Manage cookies Do not share my personal information

Commits

etapa3All usersAll time

Commits on Sep 29, 2026

feat: agregar seccion Etapa 3 en Flask (resultados ETL)72db8aa

IKCR committed 1 hour ago

feat: agregar paquete SSIS y scripts SQL para ETL de calidad de datos (Etapa 3)3c4c329

IKCR committed 1 hour ago

Commits on Sep 12, 2026

Quitar boton Descargar copia tratada de Tratamiento37319ee

IKCR committed 2 weeks ago

Mejorar visualmente nota de Nivel Regional en Perfilamiento Detallado6dd14f1

IKCR committed 2 weeks ago

Agregar filas Regionales y nota Colfirma en Perfilamiento Detallado871617d

IKCR committed 2 weeks ago

Agregar 3 filas a Reglas de integracion y estandarizacion en homologacion46c5572


IKCR committed 2 weeks ago

Agregar 2 cards a Analisis de causas en Tratamientoca35121

IKCR committed 2 weeks ago

Agregar seccion Perfilamiento Detallado por Variable y Dimension en calidad de datos65ecc48

IKCR committed 2 weeks ago



11. Enlaces del proyecto

Repositorio: <https://github.com/Tayrun/Dinamica-Empresarial>

Aplicación publicada: <https://dinamica-empresarial.onrender.com/>

Rama de la Etapa 3: <https://dinamica-empresarial.onrender.com/etapa3/resultados>

Pull Request: <https://github.com/Tayrun/Dinamica-Empresarial/pull/12>

Video: <https://youtu.be/2rTh9h73rkk>