Universidad de Cundinamarca · Extensión Chía
Ingeniería de Sistemas y Computación · CADI Minería de datos · Grupo 901T

Dinámica Empresarial

Informe técnico de la etapa 6

Conocimiento oculto

Modelos supervisados, agrupamiento y minería de texto de comentarios de YouTube con Orange Data Mining, sobre los estados financieros de empresas colombianas (SIREM)

Integrante(s)	Ingrid Katherin Caicedo Rodríguez. [PENDIENTE: completar con los demás integrantes del grupo]
Aplicación publicada	https://dinamica-empresarial.onrender.com [PENDIENTE: enlace exacto de la sección «Conocimiento Oculto» al publicarla]
Repositorio	https://github.com/Tayrun/Dinamica-Empresarial [PENDIENTE: rama y commits de la etapa 6]
Video de sustentación	[PENDIENTE: enlace del video, máximo 10 minutos]
Fecha	14 de noviembre de 2026

1. Introducción, alcance y nota sobre las capturas

La etapa 6 busca conocimiento que no se ve a simple vista en los datos del proyecto. Se trabajan tres frentes con Orange: (1) tres modelos supervisados comparados con la misma evaluación, (2) un agrupamiento sin variable objetivo y (3) minería de texto sobre comentarios de YouTube obtenidos con la API oficial. Al final se integran los hallazgos separando lo que muestra la evidencia de lo que solo son hipótesis.

Se usan únicamente los datos del proyecto (SIREM Colombia, conjunto *Estados Financieros NIIF - Estado de Situación Financiera*, datos.gov.co, pfdp-zks5) y los comentarios públicos de los videos listados en la sección 5.

Sobre las capturas: este informe incluye solo capturas que muestran widgets configurados correctamente y con resultados válidos. Se dejaron fuera, a propósito, las capturas de estados erróneos o incompletos durante el trabajo: Corpus cargado con el conjunto de ejemplo de Orange, Corpus con idioma vietnamita y variables de texto intercambiadas, Preprocess Text sin aplicar el filtro de frecuencia de documentos, Topic Modelling con el número de temas escrito pero no aplicado, conexiones «Predictions → Data» entre los aprendices y Test and Score (conexión equivocada) y los pasos intermedios de Select Columns. No se incluye ninguna captura con claves o credenciales.

2. Modelos supervisados

2.1 Pregunta, variable objetivo y datos

Pregunta: ¿se puede anticipar si una empresa tiene un endeudamiento alto a partir de su tamaño, el año del reporte y su activo total?

Variable objetivo: `Endeudamiento_Alto` = «Alto» si la razón de endeudamiento (Pasivo / Activo) es mayor que 0,60; «No alto» en otro caso. El conjunto `endeudamiento_modelo.csv` tiene 875 filas, que son las que tienen razón de endeudamiento conocida (el resto de la muestra no trae pasivo).

Clase	Filas	Proporción
No alto	541	61,8 %
Alto	334	38,2 %

Desbalance de clases: la clase «Alto» es la minoritaria (38,2 %). Un modelo que siempre responde «No alto» acierta el 61,8 %; por eso la exactitud sola no sirve para juzgar y se incluyó un modelo de referencia (Constant) y métricas centradas en la clase «Alto» (precisión, recall, F1, AUC y MCC).

Variables predictoras: Año, Tamaño y Activo_Total (y, en un segundo experimento, Log_Activo = ln del activo).

Control de fuga de información (leakage): la razón de endeudamiento es Pasivo / Activo y el patrimonio es Activo − Pasivo. Como el objetivo sale directamente de la razón, ni Pasivo, ni Patrimonio, ni Razón_Endeudamiento pueden ser predictores: llevarían la respuesta dentro. Por eso solo se usan Año, Tamaño y Activo. Además, la evaluación es por validación cruzada, de modo que ningún dato se evalúa con un modelo que lo haya visto al entrenar.

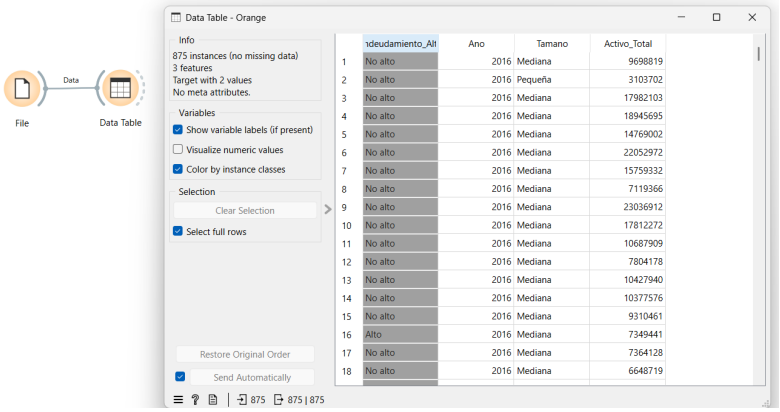


Figura 1. Widget Data Table sobre el archivo cargado: 875 instancias, 3 variables y objetivo con dos valores (Alto / No alto).

2.2 Flujo en Orange

El archivo se carga con File; cuatro aprendices (Logistic Regression, Tree, kNN y Constant) se conectan por su salida «Learner» a Test and Score, que recibe los datos de File. Todos los modelos se evalúan en el mismo widget, con los mismos pliegues.

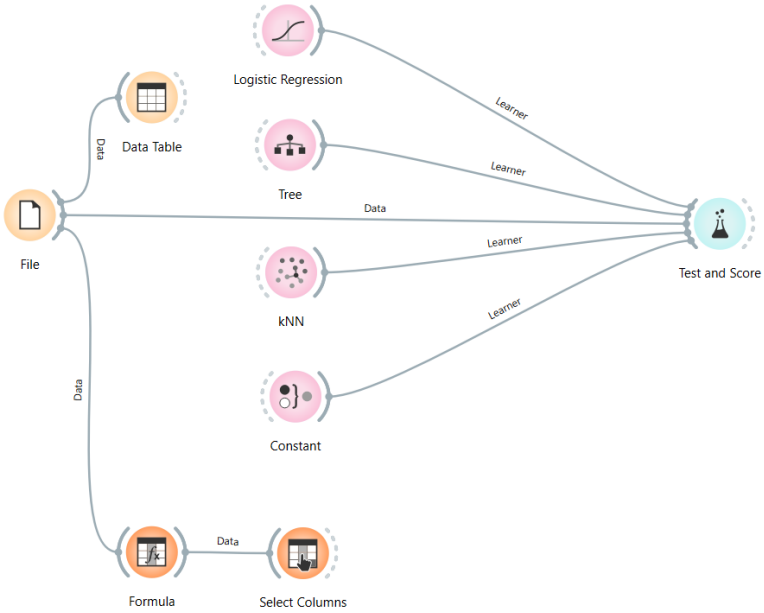


Figura 2. Flujo supervisado: File → Test and Score con cuatro aprendices conectados (Learner). Se ven además Formula y Select Columns, usados en el experimento B.

Widget	Parámetros	Conexión
File	endeudamiento_modelo.csv; objetivo Endeudamiento_Alto; Año, Tamaño y Activo_Total como variables	→ Data Table, Test and Score, Formula

Widget	Parámetros	Conexión
Formula + Select Columns	Crea Log_Activo; deja Año, Tamaño, Activo_Total y Log_Activo como variables y Endeudamiento_Alto como objetivo (experimento B)	File → Formula → Select Columns → Test and Score
Logistic Regression, Tree, kNN, Constant	Valores por defecto de cada widget; Constant predice la clase mayoritaria y es la línea base	Learner → Test and Score
Test and Score	Validación cruzada, 10 pliegues, estratificada; evaluación para la clase «Alto»; comparación por AUC	Evaluation Results → Confusion Matrix

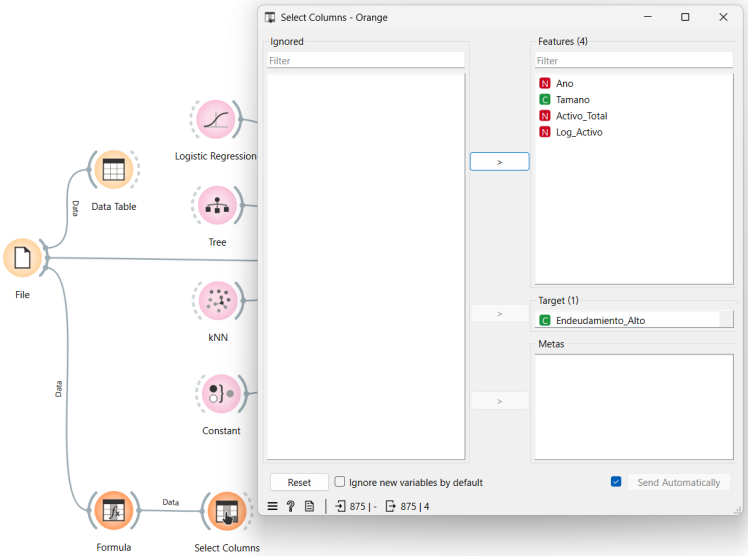


Figura 3. Select Columns del experimento B: variables Año, Tamaño, Activo_Total y Log_Activo; objetivo Endeudamiento_Alto.

2.3 Resultados con la misma evaluación (10 pliegues, estratificada)

Experimento A (Año, Tamaño, Activo_Total). Métricas para la clase «Alto»:

Modelo	AUC	Exactitud (CA)	F1	Precisión	Recall	MCC
Logistic Regression	0,468	0,618	0,000	0,000	0,000	0,000
Tree	0,530	0,605	0,117	0,397	0,069	0,008
kNN	0,543	0,578	0,376	0,432	0,332	0,067
Constant (línea base)	0,500	0,618	0,000	0,000	0,000	0,000

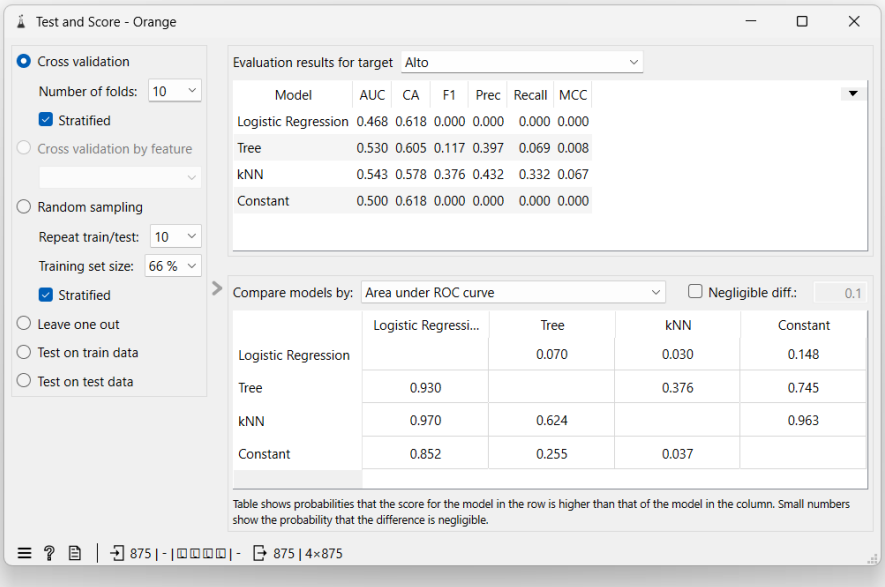


Figura 4. Test and Score, experimento A: validación cruzada de 10 pliegues estratificada y comparación de modelos por AUC.

Experimento B (se agrega Log_Activo). Valores leídos de la captura; la fila Constant queda oculta por el tamaño de la ventana y el MCC de kNN aparece cortado, por lo que no se reportan.

Modelo	AUC	Exactitud (CA)	F1	Precisión	Recall
Logistic Regression	0,415	0,618	0,006	0,500	0,003
Tree	0,530	0,605	0,117	0,397	0,069
kNN	0,501	0,533	0,326	0,363	0,296

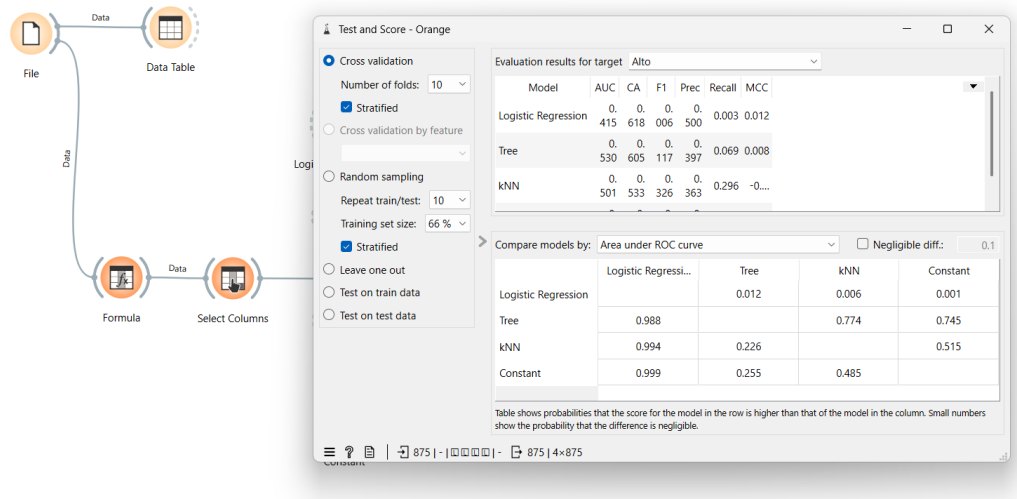


Figura 5. Test and Score, experimento B, con Log_Activo como variable adicional.

2.4 Matriz de confusión del modelo elegido

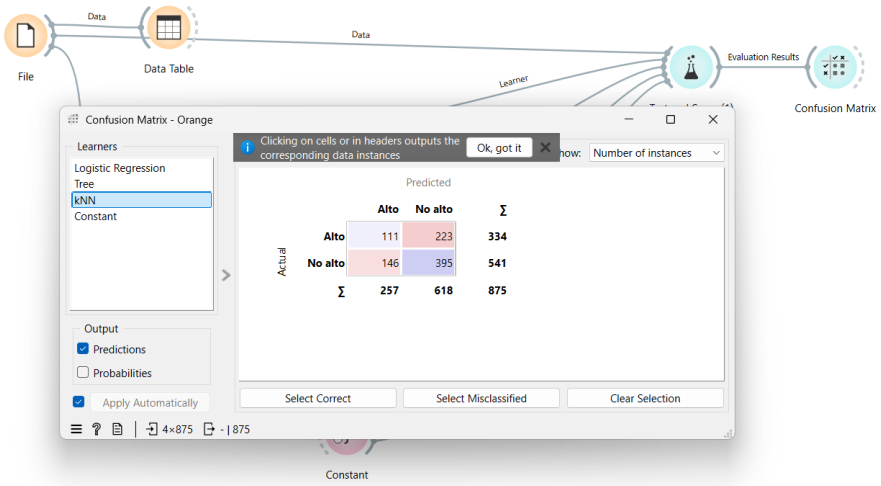


Figura 6. Matriz de confusión de kNN (experimento A), en número de instancias; filas = real, columnas = predicho.

	Predicho Alto	**Predicho No alto**	**Total**
Real Alto	111 (verdaderos positivos)	223 (falsos negativos)	334
Real No alto	146 (falsos positivos)	395 (verdaderos negativos)	541
Total	257	618	875

Comprobación: exactitud = (111 + 395) / 875 = 0,578; precisión = 111 / 257 = 0,432; recall = 111 / 334 = 0,332, que coinciden con la tabla de Orange. El modelo detecta uno de cada tres empresas con endeudamiento alto, y cuando dice «Alto» acierta poco más de 4 de cada 10 veces.

2.5 Modelo elegido y justificación

Se elige **kNN del experimento A**. Es el único modelo que detecta empresas de la clase «Alto» de forma apreciable (recall 0,332 frente a 0,069 del árbol y 0 de la regresión logística) y tiene el mejor F1 (0,376), el mejor AUC (0,543) y el mejor MCC (0,067). La probabilidad de que su AUC sea mayor que la de la línea base Constant es 0,963 y mayor que la de la regresión logística, 0,970; frente al árbol es solo 0,624, es decir, esa diferencia no es concluyente.

Advertencia importante: ningún modelo es realmente útil para predecir. El AUC del mejor modelo (0,543) está casi en el nivel del azar (0,5), su exactitud (0,578) queda por debajo de la línea base (0,618) y el MCC es cercano a cero. Elegir kNN significa «el menos malo y el único que detecta algo», no «un buen modelo». La regresión logística tiene AUC menor que 0,5 y no predice nunca «Alto»: coincide con la línea base en exactitud porque se comporta como ella.

Agregar Log_Activo (experimento B) no mejora nada: el árbol da exactamente lo mismo, como era de esperar porque el logaritmo no cambia el orden del activo, y kNN empeora (AUC 0,501). Eso indica que el tamaño y el nivel del activo, junto con el año, casi no contienen información sobre qué tan endeudada está una empresa.

Interpretación (hipótesis, no demostrada): el nivel de endeudamiento depende de la composición del pasivo y del modelo de negocio de cada empresa, variables que esta muestra no tiene y que, para el pasivo, se excluyeron a propósito por fuga de información. Además, solo 875 de 9.163 empresas tienen razón de endeudamiento conocida, así que el modelo se entrenó con una porción pequeña y posiblemente sesgada de la muestra.

3. Agrupamiento sin variable objetivo

3.1 Datos y variables

Se agrupan 9.163 filas (una por empresa) del archivo `empresas_clustering.csv`, sin variable objetivo.

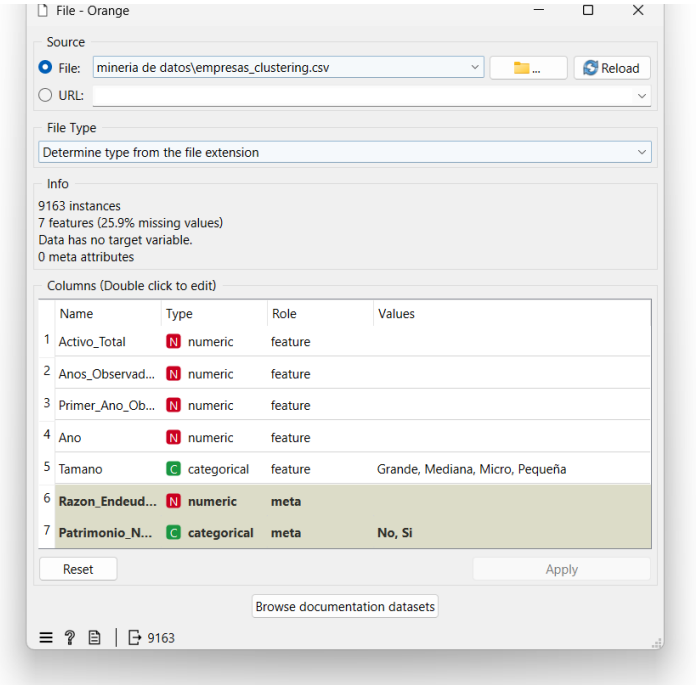


Figura 7. Widget File con empresas_clustering.csv: 9.163 instancias, sin variable objetivo; Razon_Endeudamiento y Patrimonio_Negativo como metas.

Variable	Papel	Justificación
Anos_Observados	Entra al agrupamiento	Cuántos años aparece la empresa en la muestra (permanencia)
Primer_Ano_Observado	Entra al agrupamiento	Cohorte de ingreso a la muestra
Log_Activo	Entra al agrupamiento	Logaritmo natural del activo total; el activo es muy asimétrico y el logaritmo evita que unas pocas empresas enormes dominen la distancia
Activo_Total, Año, Tamaño	Meta (no entra)	Activo_Total ya está representado por Log_Activo y Tamaño se deriva del activo; se conservan solo para describir los grupos
Razon_Endeudamiento, Patrimonio_Negativo	Meta (no entra)	Son el resultado financiero que se quiere interpretar; se usan después, para caracterizar los grupos, sin que influyan en ellos

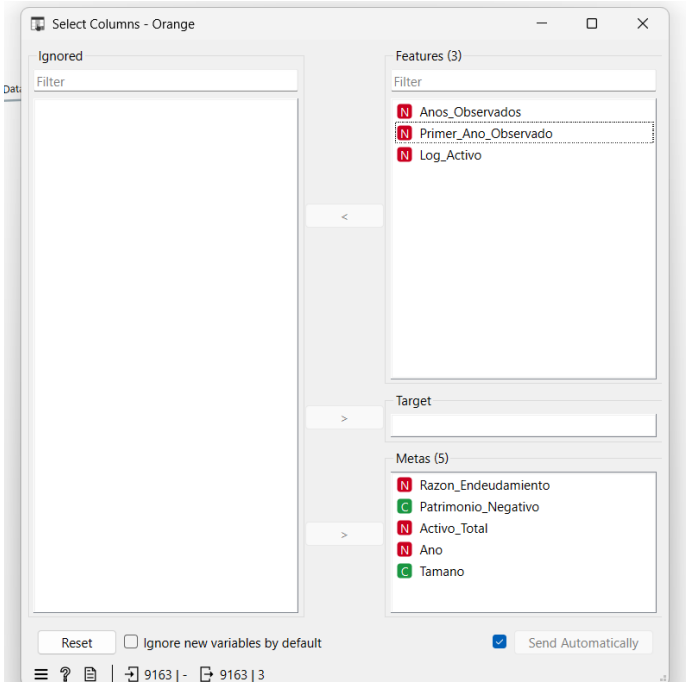


Figura 8. Select Columns del agrupamiento: tres variables de entrada y cinco metas, sin objetivo.

3.2 Normalización y elección de k

k-Means de Orange con «Normalize columns» activado (cada variable se estandariza, de modo que ninguna pese más por su escala), inicialización KMeans++, 10 reinicios y máximo de 300 iteraciones. Se probaron k de 2 a 8 y se comparó el coeficiente de silueta.

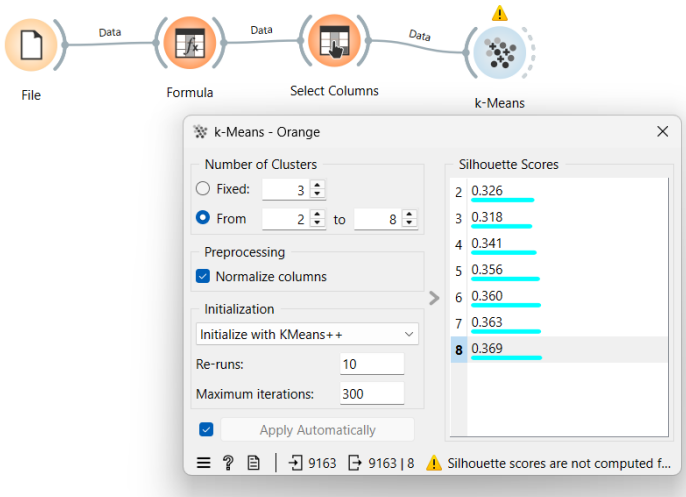


Figura 9. Flujo File → Formula → Select Columns → k-Means y puntajes de silueta para k = 2 a 8. El aviso amarillo indica que Orange no calcula la silueta por instancia con más de 5.000 filas.

k	2	3	4	5	6	7	8
Silueta	0,326	0,318	0,341	0,356	0,360	0,363	0,369

Los valores se verificaron con un cálculo independiente (estandarización z, KMeans de scikit-learn y silueta sobre una muestra de 5.000 filas): coinciden con los de Orange hasta el tercer decimal, y los tamaños de grupo para k = 4 también.

Decisión: k = 4. La silueta sube muy poco después de k = 4 (de 0,341 a 0,369 en k = 8) y no hay un máximo claro; k = 3 es peor que k = 2 y k = 4 recupera. Se prefiere k = 4 porque da grupos que se pueden describir y comparar sin dividir demasiado. La silueta de 0,34 indica una estructura débil: los grupos existen, pero se traslapan.

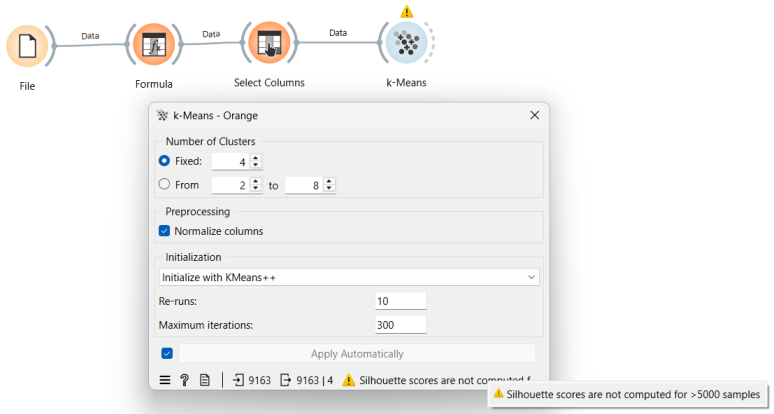


Figura 10. k-Means con número fijo de grupos k = 4, normalización activada.

3.3 Caracterización de los grupos

Con Group by sobre la columna Cluster se calculan promedio, mediana y conteo de cada variable. Las columnas de endeudamiento solo cuentan las empresas con razón conocida (n = 351, 104, 263 y 157).

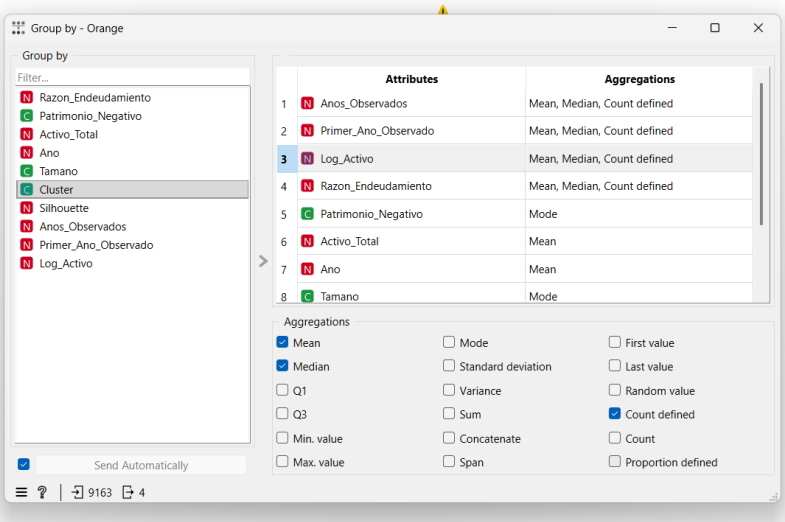


Figura 11. Group by agrupando por Cluster, con promedio, mediana y conteo para las variables numéricas.

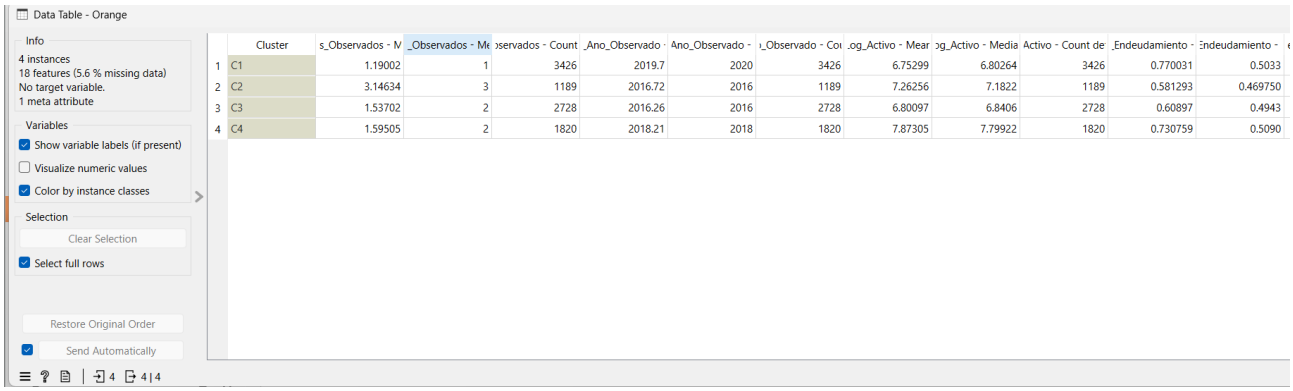


Figura 12. Resultado de Group by (parte izquierda): años observados, primer año, Log_Activo y empresas por grupo.

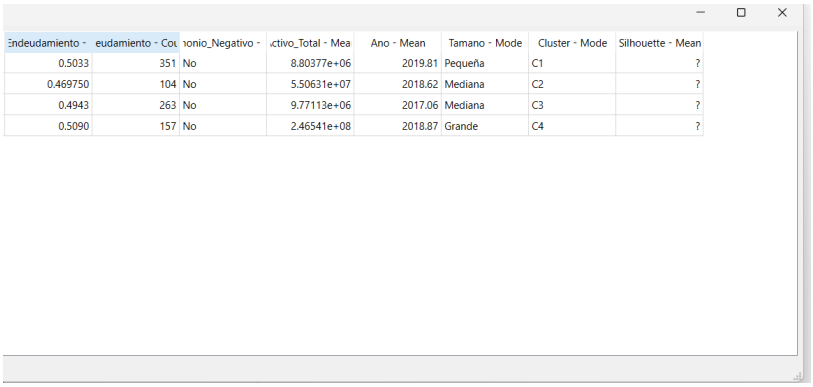


Figura 13. Resultado de Group by (parte derecha): razón de endeudamiento, patrimonio negativo, activo total medio, año medio y tamaño más frecuente.

Grupo	Empresas	Años obs. (media)	Primer año (mediana)	Log_Activo (mediana)	Activo total medio	Tamaño más frecuente	Razón endeud. (mediana / media)
C1	3.426	1,19	2020	6,80	8,80e6	Pequeña	0,503 / 0,770
C2	1.189	3,15	2016	7,18	5,51e7	Mediana	0,470 / 0,581
C3	2.728	1,54	2016	6,84	9,77e6	Mediana	0,494 / 0,609
C4	1.820	1,60	2018	7,80	2,47e8	Grande	0,509 / 0,731

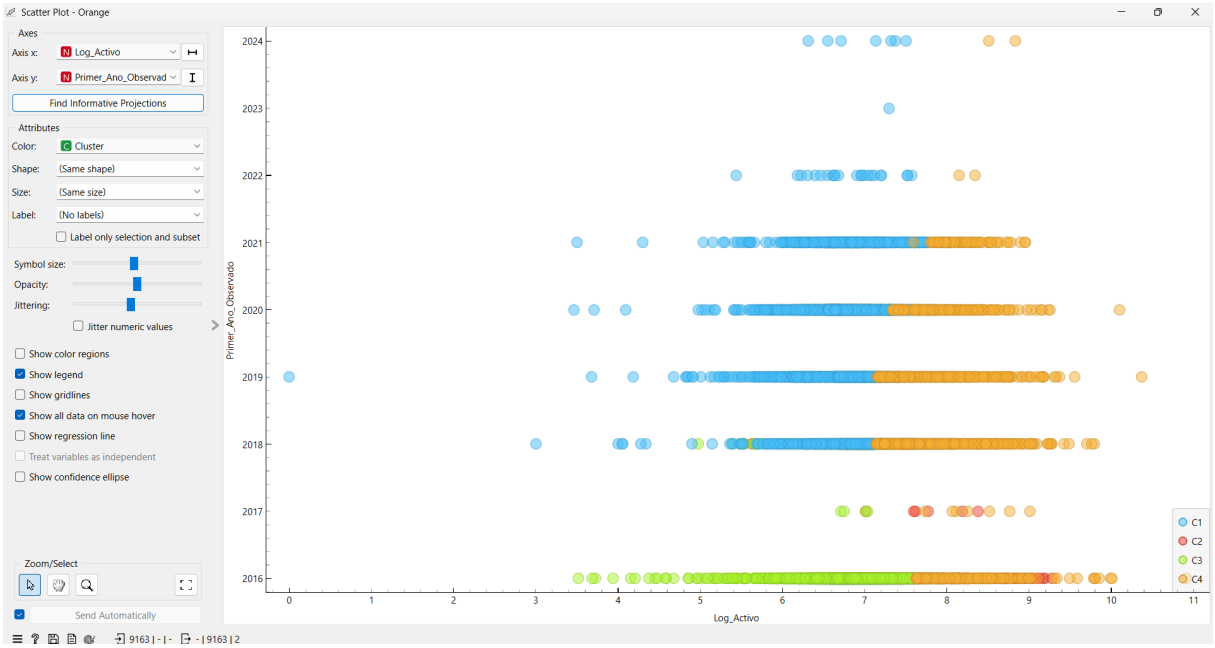


Figura 14. Diagrama de dispersión: Log_Activo (eje x) contra primer año observado (eje y), con color por grupo (C1 azul, C2 rojo, C3 verde, C4 naranja).

Lectura de los grupos (los nombres son descriptivos, interpretación del equipo):

- **C1, entrantes recientes de activo pequeño** (3.426): se observan en promedio 1,19 años y empiezan hacia 2020.
- **C2, permanentes de larga trayectoria** (1.189): las que se ven durante 3 años desde 2016; activo mediano-alto.
- **C3, cohorte de 2016 con pocos años** (2.728): aparecen desde 2016 pero solo 1 o 2 años; activo pequeño-mediano.
- **C4, empresas grandes** (1.820): activo muy superior (log mediano 7,80; activo medio 2,47e8); ingresan en todos los años, con mediana en 2018.

En el diagrama se ve que los grupos se separan por el nivel del activo (C4 a la derecha) y por el año de ingreso (C3 en 2016, C1 desde 2018). C2 queda tapado por otros puntos en 2016 porque comparte primer año con C3. **Hallazgo clave:** la mediana de la razón de endeudamiento es casi igual en los cuatro grupos (0,47 a 0,51) y todos tienen patrimonio negativo «No» como valor más frecuente. Las medias más altas (0,77 en C1 y 0,73 en C4) vienen de unos pocos valores extremos: son mayores que las medianas en los cuatro grupos. Es decir, la trayectoria y el tamaño no diferencian el endeudamiento, lo que va en la misma línea que los modelos supervisados.

4. Minería de texto: comentarios de YouTube

4.1 Propósito

Saber qué razones mencionan los usuarios sobre por qué las empresas colombianas se endeudan, entran en crisis, cierran o sobreviven, y contrastarlo con lo que muestran los datos del modelo. Los comentarios no se usan para medir ni sustituir los datos financieros, solo para generar preguntas e hipótesis.

4.2 Obtención con la API oficial y criterios

Se usó la API YouTube Data API v3 (habilitada en un proyecto de Google Cloud). La clave se guardó como secreto de Google Colab y el script la lee de allí; **la clave no aparece en el código, en el repositorio ni en este informe**.

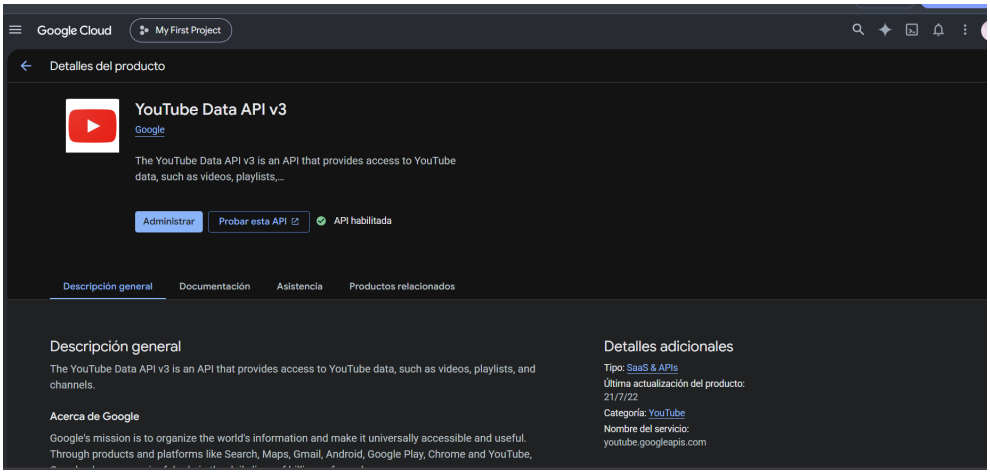


Figura 15. Detalle de YouTube Data API v3 con el estado «API habilitada» en Google Cloud (sin credenciales a la vista).

Criterio	Valor
Fecha de extracción	14 de noviembre de 2026
Búsquedas	«por qué cierran las empresas en Colombia», «endeudamiento de las pymes en Colombia», «quiebra de empresas en Colombia», «cómo sobrevive una pyme en Colombia crisis», «insolvencia empresarial Colombia»
Parámetros de búsqueda	Solo videos; idioma de relevancia español; región Colombia; búsqueda segura moderada; 10 resultados por consulta
Selección de videos	Se descartan videos con menos de 50 comentarios y se usan los 8 con más comentarios
Comentarios por video	Solo comentarios principales (no respuestas), orden por relevancia, texto plano, máximo 300 por video
Relevancia del video (criterio editorial)	Directa: trata cierre, crisis o rescate de negocios; contexto: trata el entorno macro (deuda pública, reforma tributaria); tangencial: trata rentabilidad o emprendimiento en general
Datos que se conservan	Texto, fecha, número de «me gusta», video e idioma. Se descartan nombres, identificadores de autores y enlaces a canales; los comentarios reciben un identificador secuencial propio

4.3 Videos consultados

Video (enlace)	Canal	Publicado	Total en YouTube	Extraídos	Limpios	Relevancia
La Pulla: ¿El Gobierno se quedó sin plata? Por esto Colombia está tan endeudada https://www.youtube.com/watch?v=pVfj46LrXGA	La Pulla	2025-07-10	2.361	300	191	contexto
Medellín cierra restaurantes por altos costos de arriendos https://www.youtube.com/watch?v=rW-6hpC8izw	Somos Colombia	2026-10-20	1.464	300	77	directa
3 negocios que ya no son rentables https://www.youtube.com/watch?v=QvaC0FIaANk	Constructora de Negocios Podcast	2024-09-07	780	300	147	tangencial
Luis Carlos Reyes: «Colombia no está cerca de la quiebra como dice el Gobierno» https://www.youtube.com/watch?v=T_Vc1YfDSwQ	FRANCE 24 Español	2026-10-31	310	130	62	contexto
Tulio Gómez, de La Montaña Agromercados (entrevista) https://www.youtube.com/watch?v=N-WKlSrkdeQ	Noticias Caracol	2022-03-21	307	222	89	tangencial
15 consejos prácticos para salir de una crisis económica https://www.youtube.com/watch?v=zm3KYUBUYnE	NegocioStart	2019-10-14	166	60	38	directa
Consejo para ser un empresario exitoso https://www.youtube.com/watch?v=H97hH_kvyzU	Eduardo Cardenas Mx	2023-06-10	141	94	35	tangencial
4 acciones para rescatar un negocio en quiebra https://www.youtube.com/watch?v=nd0dNQrazxo	Emprendedor Eficaz	2021-07-22	55	27	13	directa
Total			5.584	1.433	652	

Restricciones: la API tiene cuota diaria; solo se descargaron comentarios principales, por lo que la cifra de «comentarios totales» (que incluye respuestas) es mayor que la de extraídos; el orden por relevancia sesga hacia comentarios con más interacción; solo hay comentarios públicos y vigentes el día de la extracción, que pueden cambiar o borrarse después. Por respeto a los autores, el archivo publicado no incluye identificadores de usuarios.

4.4 Limpieza documentada

Paso	Criterio	Descartados	Quedan
0. Extraídos	Salida de la API, comentarios de primer nivel	0	1.433
1. Duplicados por identificador	Mismo comentario descargado dos veces	0	1.433
2. Vacíos	Solo emojis, números, signos o menciones	15	1.418
3. Duplicados de texto	Mismo texto normalizado (copias, spam repetido, consignas); se conserva el de más «me gusta»	69	1.349
4. Idioma	Heurística de palabras funcionales: se descarta lo que no está en español	0	1.349
5a. Publicidad	Contiene enlace, WhatsApp, Telegram o teléfono	2	1.347
5b. Demasiado corto	Menos de 3 palabras (saludos, aplausos, «gracias»)	66	1.281
5c. Sobre el formato del video	Quejas del tipo «¿y el tercero?» sin contenido sobre el tema	43	1.238
5d. Sin vocabulario del dominio	Ninguna raíz del léxico económico-empresarial (empresa, negocio, quiebra, plata, pagar, interés, empleo, etc.)	586	652

El resultado es un corpus de **652 comentarios** (45,5 % de los extraídos). El último filtro es el más fuerte (586 descartados) y es una decisión de relevancia: elimina comentarios sin relación con lo económico, pero puede dejar fuera comentarios pertinentes escritos con otras palabras. En la limpieza también se enmascaran enlaces, menciones y teléfonos dentro del texto. Los comentarios descartados se guardaron solo para auditoría interna y no se publican.

4.5 Flujo de minería de texto en Orange

Se usa el complemento Text de Orange. El flujo parte del corpus limpio, lo preprocesa y obtiene temas con modelado de tópicos (LDA); después se reúnen los resultados por video.

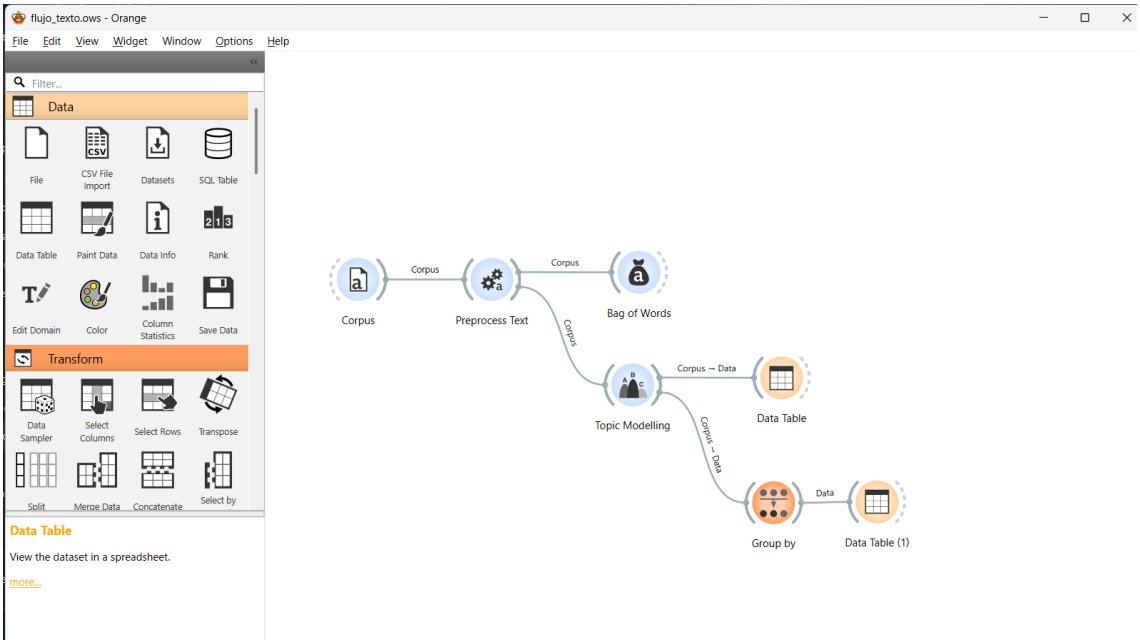


Figura 16. Lienzo del flujo de texto: Corpus → Preprocess Text → Bag of Words; Preprocess Text → Topic Modelling → Data Table; Topic Modelling → Group by → Data Table (1).

Widget	Parámetros	Conexión
Corpus	comentarios_limpios.csv; idioma español; variable de texto «texto» usada, «id» ignorada y como título; 652 documentos	→ Preprocess Text
Preprocess Text	Tokenización por expresión regular \w+; stopwords en español más la lista propia stopwords_extra.txt (50 palabras sin valor temático); se filtran números; filtro de frecuencia de documentos absoluta entre 3 y 300; sin lematización. Resultado: 4.959 tokens y 688 términos distintos	→ Bag of Words y Topic Modelling
Bag of Words	Frecuencia de término «Count», frecuencia de documento «IDF», sin regularización; atributos ocultos	Matriz documento-término de 652 filas (representación del corpus)
Topic Modelling	Latent Dirichlet Allocation, 5 temas	→ Data Table y Group by
Data Table	Muestra los 652 comentarios con la probabilidad de cada tema	Salida de revisión
Group by	Agrupa por video y calcula el promedio de la probabilidad de cada tema	→ Data Table (1)

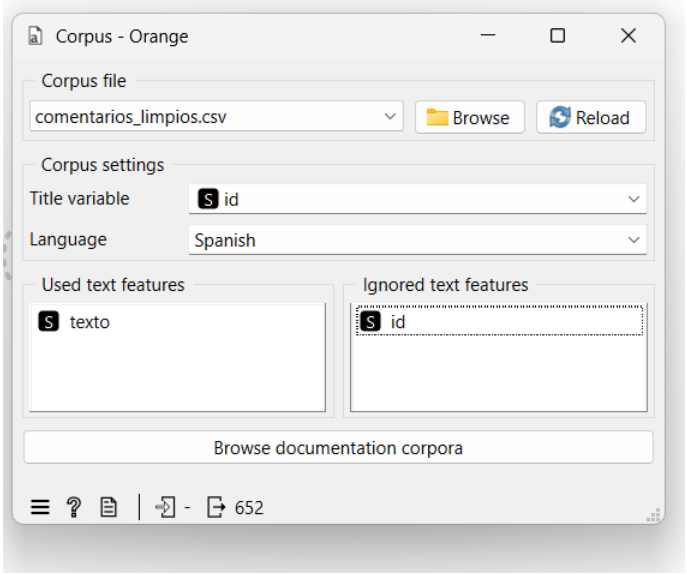


Figura 17. Widget Corpus: archivo comentarios_limpios.csv, idioma español, variable «texto» en uso; 652 documentos.

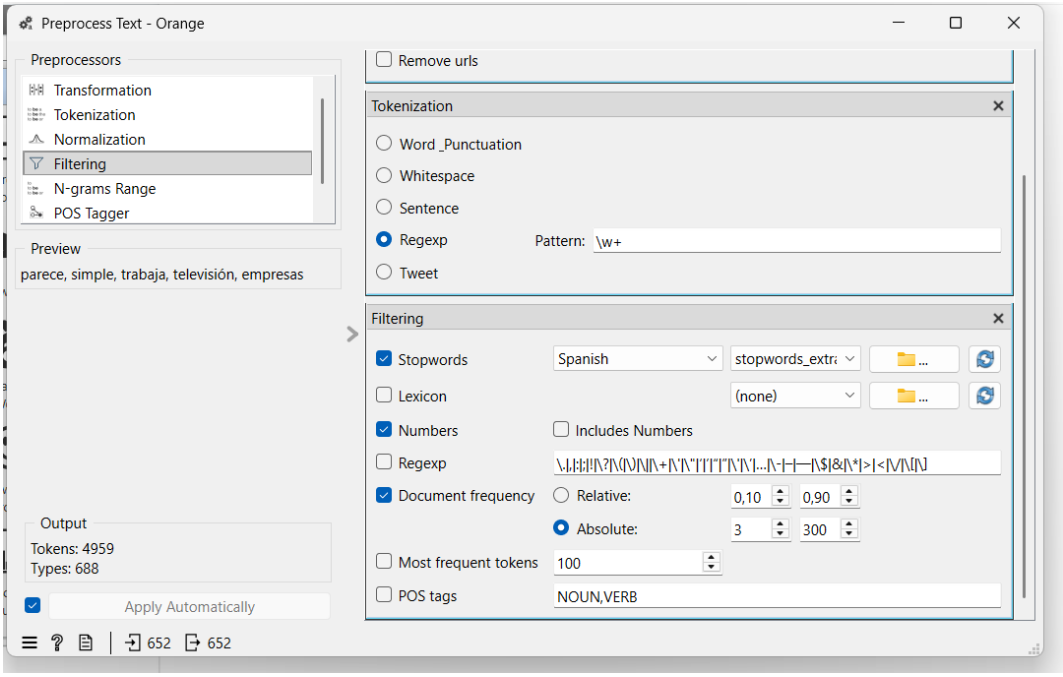


Figura 18. Preprocess Text con los filtros aplicados: salida de 4.959 tokens y 688 términos distintos.

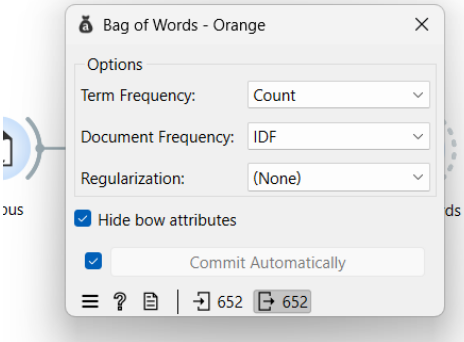


Figura 19. Widget Bag of Words con frecuencia de término «Count» y frecuencia de documento «IDF».

4.6 Elección del número de temas

Se probó LDA con 3 a 7 temas y se comparó la coherencia de los temas (mayor es mejor): k = 3: 0,37471; k = 4: 0,37968; **k = 5: 0,39494**; k = 6: 0,38593; k = 7: 0,39139. Se eligió k = 5 por tener la coherencia más alta (perplejidad logarítmica 111,03583). Como LDA es estocástico, otra ejecución puede variar en las milésimas; las diferencias entre valores de k son pequeñas y la elección es razonable, no concluyente.

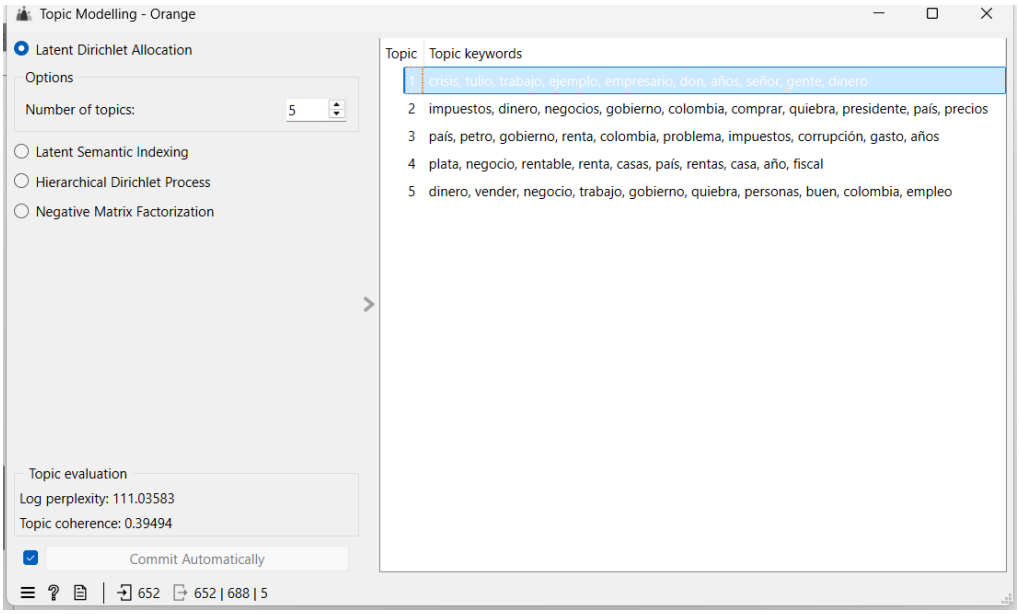
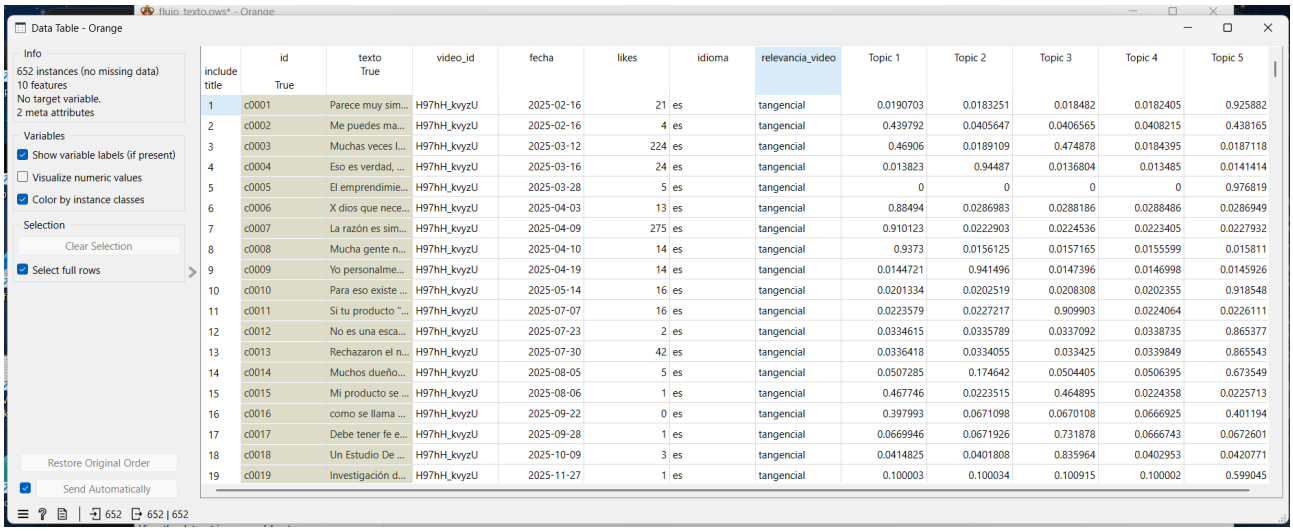


Figura 20. Topic Modelling con 5 temas: palabras clave de cada tema y evaluación (perplejidad y coherencia).

4.7 Temas encontrados y su interpretación

Tema	Palabras clave principales	Lectura (interpretación nuestra)
1	crisis, tulio, trabajo, ejemplo, empresario, don, años, señor, gente, dinero	Experiencia personal y consejos de empresarios en la crisis. Contiene el nombre «Tulio» y tratamientos («don», «señor») que vienen de una entrevista concreta: es un artefacto de ese video
2	impuestos, dinero, negocios, gobierno, colombia, comprar, quiebra, presidente, país, precios	Impuestos, precios y quiebra de negocios
3	país, petro, gobierno, renta, colombia, problema, impuestos, corrupción, gasto, años	Política fiscal y gobierno; discusión pública sobre gasto y corrupción
4	plata, negocio, rentable, renta, casas, país, rentas, casa, año, fiscal	Rentabilidad de los negocios y negocios de renta (arriendos de inmuebles). «Renta» es ambigua: puede ser ingreso, impuesto o arriendo
5	dinero, vender, negocio, trabajo, gobierno, quiebra, personas, buen, colombia, empleo	Vender, sostener el negocio y el empleo



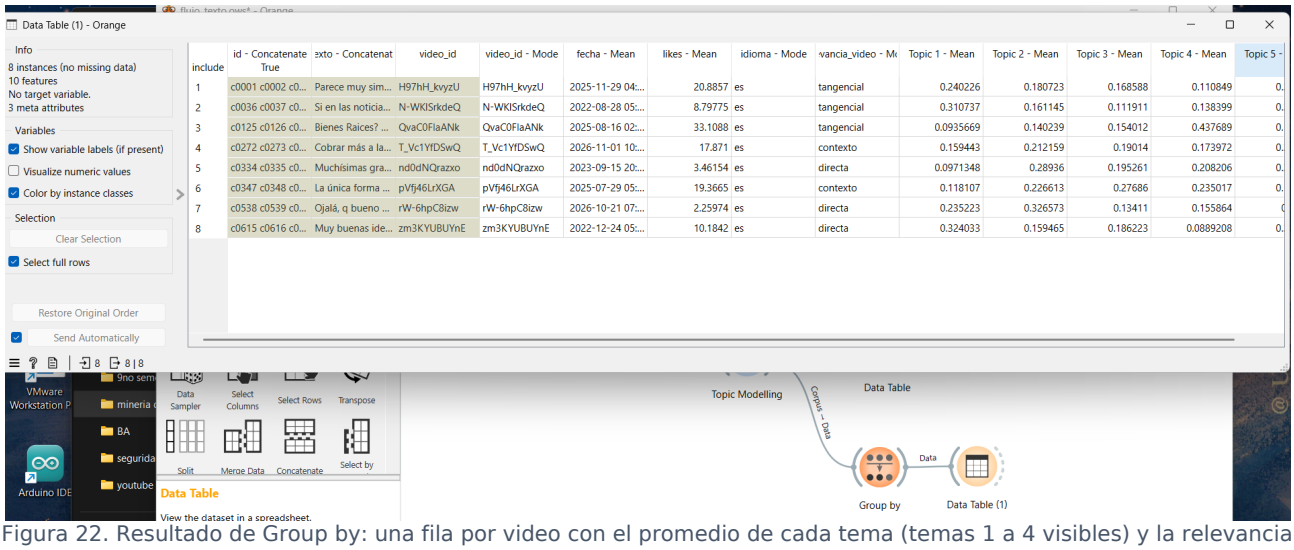
include	id	texto	video_id	fecha	likes	idioma	relevancia_video	Topic 1	Topic 2	Topic 3	Topic 4	Topic 5
	title	True										
1	c0001	Parece muy sim...	H97hH_kvyzU	2025-02-16	21	es	tangencial	0.0190703	0.0183251	0.018482	0.0182405	0.925882
2	c0002	Me puedes ma...	H97hH_kvyzU	2025-02-16	4	es	tangencial	0.439792	0.0405647	0.0406565	0.0408215	0.438165
3	c0003	Muchas veces l...	H97hH_kvyzU	2025-03-12	224	es	tangencial	0.46906	0.0189109	0.474878	0.0184395	0.0187118
4	c0004	Eso es verdad, ...	H97hH_kvyzU	2025-03-16	24	es	tangencial	0.013823	0.94487	0.0136804	0.013485	0.0141414
5	c0005	El emprendimie...	H97hH_kvyzU	2025-03-28	5	es	tangencial	0	0	0	0	0.976819
6	c0006	X dios que nece...	H97hH_kvyzU	2025-04-03	13	es	tangencial	0.88494	0.0286983	0.0288186	0.0288486	0.0286949
7	c0007	La razón es sim...	H97hH_kvyzU	2025-04-09	275	es	tangencial	0.910123	0.0222903	0.0224536	0.0223405	0.0227932
8	c0008	Mucha gente n...	H97hH_kvyzU	2025-04-10	14	es	tangencial	0.9373	0.0156125	0.0157165	0.0155599	0.015811
9	c0009	Yo personalme...	H97hH_kvyzU	2025-04-19	14	es	tangencial	0.0144721	0.941496	0.0147396	0.0146998	0.0145926
10	c0010	Para eso existe ...	H97hH_kvyzU	2025-05-14	16	es	tangencial	0.0201334	0.0202519	0.0208308	0.0202355	0.918548
11	c0011	Si tu producto "...	H97hH_kvyzU	2025-07-07	16	es	tangencial	0.0223579	0.0227217	0.909903	0.0224064	0.0226111
12	c0012	No es una esca...	H97hH_kvyzU	2025-07-23	2	es	tangencial	0.0334615	0.0335789	0.0337092	0.0338735	0.865377
13	c0013	Rechazaron el n...	H97hH_kvyzU	2025-07-30	42	es	tangencial	0.0336418	0.0334055	0.033425	0.0339849	0.865543
14	c0014	Muchos dueño...	H97hH_kvyzU	2025-08-05	5	es	tangencial	0.0507285	0.174642	0.0504405	0.0506395	0.673549
15	c0015	Mi producto se ...	H97hH_kvyzU	2025-08-06	1	es	tangencial	0.467746	0.0223515	0.464895	0.0224358	0.0225713
16	c0016	como se llama ...	H97hH_kvyzU	2025-09-22	0	es	tangencial	0.397993	0.0671098	0.0670108	0.0666925	0.401194
17	c0017	Debe tener fe e...	H97hH_kvyzU	2025-09-28	1	es	tangencial	0.0669946	0.0671926	0.731878	0.0666743	0.0672601
18	c0018	Un Estudio De ...	H97hH_kvyzU	2025-10-09	3	es	tangencial	0.0414825	0.0401808	0.835964	0.0402953	0.0420771
19	c0019	Investigación d...	H97hH_kvyzU	2025-11-27	1	es	tangencial	0.100003	0.100034	0.100915	0.100002	0.599045

Figura 21. Data Table con los 652 comentarios y la probabilidad de cada uno de los cinco temas (columnas Topic 1 a Topic 5).

4.8 Temas por video

Group by con el promedio de la probabilidad de cada tema en cada video (8 filas). El tema principal de cada video coincide con su asunto, lo que da confianza en que los temas no son ruido:

Video	T1	T2	T3	T4	T5	Tema principal
H97hH_kvyzU (consejo de empresario)	0,240	0,181	0,169	0,111	0,299	T5
N-WKlSrkdeQ (Tulio Gómez)	0,311	0,161	0,112	0,138	0,277	T1
QvaC0FIaANk (3 negocios no rentables)	0,094	0,140	0,154	0,438	0,173	T4
T_Vc1YfDSwQ (Reyes, FRANCE 24)	0,159	0,212	0,190	0,174	0,264	T5
nd0dNQrazxo (rescatar un negocio)	0,097	0,289	0,195	0,208	0,210	T2
pVfj46LrXGA (La Pulla, deuda pública)	0,118	0,227	0,277	0,235	0,141	T3
rW-6hpC8izw (restaurantes en Medellín)	0,235	0,327	0,134	0,156	0,148	T2
zm3KYUBUYnE (salir de una crisis)	0,324	0,159	0,186	0,089	0,237	T1



include	id - Concatenate	exto - Concatenat	video_id	video_id - Mode	fecha - Mean	likes - Mean	idioma - Mode	vancia_video - Mo	Topic 1 - Mean	Topic 2 - Mean	Topic 3 - Mean	Topic 4 - Mean	Topic 5 -
	True												
1	c0001 c0002 c0...	Parece muy sim...	H97hH_kvyzU	H97hH_kvyzU	2025-11-29 04:...	20.8857	es	tangencial	0.240226	0.180723	0.168588	0.110849	0.
2	c0036 c0037 c0...	Si en las noticia...	N-WKlSrkdeQ	N-WKlSrkdeQ	2022-08-28 05:...	8.79775	es	tangencial	0.310737	0.161145	0.111911	0.138399	0.
3	c0125 c0126 c0...	Bienes Raíces? ...	QvaC0FIaANk	QvaC0FIaANk	2025-08-16 02:...	33.1088	es	tangencial	0.0935669	0.140239	0.154012	0.437689	0.
4	c0272 c0273 c0...	Cobrar más a la...	T_Vc1YfDSwQ	T_Vc1YfDSwQ	2026-11-01 10:...	17.871	es	contexto	0.159443	0.212159	0.19014	0.173972	0.
5	c0334 c0335 c0...	Muchísimas gra...	nd0dNQrazxo	nd0dNQrazxo	2023-09-15 20:...	3.46154	es	directa	0.0971348	0.28936	0.195261	0.208206	0.
6	c0347 c0348 c0...	La única forma ...	pVfj46LrXGA	pVfj46LrXGA	2025-07-29 05:...	19.3665	es	contexto	0.118107	0.226613	0.27686	0.235017	0.
7	c0538 c0539 c0...	Ojalá, q bueno ...	rW-6hpC8izw	rW-6hpC8izw	2026-10-21 07:...	2.25974	es	directa	0.235223	0.326573	0.13411	0.155864	0
8	c0615 c0616 c0...	Muy buenas ide...	zm3KYUBUYnE	zm3KYUBUYnE	2022-12-24 05:...	10.1842	es	directa	0.324033	0.159465	0.186223	0.0889208	0.

Figura 22. Resultado de Group by: una fila por video con el promedio de cada tema (temas 1 a 4 visibles) y la relevancia del video.

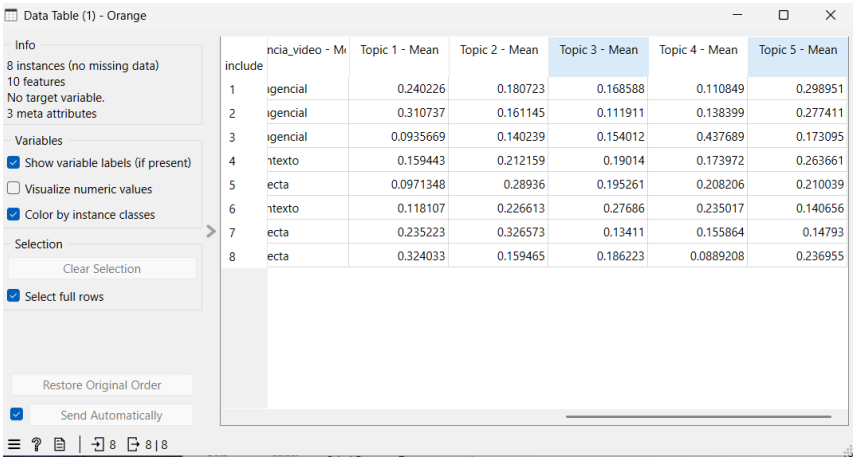


Figura 23. Misma tabla desplazada para ver el tema 5 y la relevancia del video.

Lecturas: el video de rentabilidad (QvaC0FIaANk) concentra el tema 4 (0,438); el de La Pulla sobre deuda pública es el que más habla de gobierno y país (tema 3, 0,277); el de cierre de restaurantes en Medellín destaca el tema 2, impuestos, precios y quiebra (0,327). En varios videos ningún tema supera 0,33, así que los comentarios mezclan asuntos y los temas son tendencias, no categorías limpias.

4.9 Alcance y límites

- Los comentarios **no representan a toda la población** ni a todas las empresas colombianas: son opiniones de quienes ven y comentan videos de YouTube, escogidos con cinco búsquedas concretas y 8 videos.
- Los videos son de naturaleza distinta (política fiscal, restaurantes, consejos de negocios, México), y un tema del corpus puede deberse al video y no a una preocupación general.
- El filtro por léxico y el orden por relevancia pueden sesgar el corpus hacia comentarios con vocabulario económico y muchos «me gusta».
- Uno de los videos (H97hH_kvyzU, canal de México) es tangencial y aporta 35 comentarios; los videos con menos comentarios (nd0dNQrazxo, 13) pesan poco.
- Los temas de LDA son una herramienta para explorar: no prueban causas.

5. Conclusiones integradas

Se separa lo que respalda la evidencia de este informe de lo que son hipótesis para trabajos posteriores.

5.1 Evidencia

- **El nivel de endeudamiento no se anticipa con tamaño, año y activo.** Con validación cruzada de 10 pliegues sobre 875 empresas, el mejor modelo (kNN) logra AUC 0,543, exactitud 0,578 y F1 0,376, y no supera la línea base en exactitud (0,618).
- **Los grupos por trayectoria y tamaño no se diferencian por endeudamiento.** Los cuatro grupos tienen una mediana de razón de endeudamiento entre 0,47 y 0,51 (silueta 0,341, estructura débil).
- **Estos dos resultados se refuerzan entre sí:** en ambos, las variables de tamaño y permanencia no explican la deuda.
- **Los comentarios de los videos giran alrededor de impuestos, gobierno, precios, rentabilidad, rentas (arriendos) y empleo** (cinco temas, coherencia 0,395), con perfiles

distintos por video que coinciden con el asunto de cada uno.

5.2 Hipótesis (no demostradas con los datos del proyecto)

- La carga tributaria y los costos de arriendo aparecen como razones de cierre y de crisis en los comentarios, pero los datos financieros del proyecto no tienen variables de impuestos ni de arriendo para comprobarlo.
- El endeudamiento depende de la composición del pasivo y del sector, variables ausentes en esta muestra; esto explicaría por qué el tamaño y el activo no predicen.
- La percepción pública (tema 3, política fiscal) puede estar influida por el contexto de cada video y no refleja necesariamente lo que viven las empresas.

5.3 Qué falta y qué haríamos

- Conseguir pasivo corriente y no corriente, sector y ubicación para volver a intentar el modelo supervisado; hoy solo 875 de 9.163 empresas tienen razón de endeudamiento conocida.
- Ampliar la muestra de comentarios con más videos y buscar fuentes distintas, y validar los temas con una lectura manual de una muestra de comentarios.
- Recalcular los modelos con una definición alternativa del objetivo (otros umbrales de la razón) y comparar.

6. Reproducibilidad y archivos

Archivo	Qué contiene
flujo_supervisado.ows	Flujo de Orange del modelado supervisado (File, Formula, Select Columns, cuatro aprendices, Test and Score, Confusion Matrix)
flujo_clustering.ows	Flujo de Orange del agrupamiento (File, Formula, Select Columns, k-Means, Group by, Scatter Plot)
flujo_texto.ows	Flujo de Orange de minería de texto (Corpus, Preprocess Text, Bag of Words, Topic Modelling, Group by, Data Table)
colab_youtube.py	Extracción de comentarios con la API de YouTube desde Google Colab; la clave se lee de un secreto de Colab y no se incluye
limpiar_comentarios.py	Limpieza documentada de los comentarios; genera comentarios_limpios.csv, log_limpieza.csv y videos_resumen.csv
comentarios_limpios.csv, log_limpieza.csv, videos_resumen.csv, stopwords_extra.txt	Corpus limpio sin identificadores de autores, registro de limpieza, tabla de videos con enlaces y lista de stopwords adicionales
endeudamiento_modelo.csv, empresas_clustering.csv	Conjuntos derivados del modelo del proyecto, con las columnas usadas en esta etapa

Para reproducir: ejecutar `colab_youtube.py` en Colab con un secreto `YOUTUBE_API_KEY` propio, ejecutar `python limpiar_comentarios.py comentarios_crudos.csv videos_consultados.csv salida` y abrir los flujos .ows en Orange (con el complemento Text) apuntando a los archivos. Los comentarios en bruto y los descartados no se publican; la regeneración con la API dará un conjunto parecido pero no idéntico, porque los comentarios cambian con el tiempo.

7. Referencias y enlaces

- Superintendencia de Sociedades de Colombia. *Estados Financieros NIIF - Estado de Situación Financiera* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/Econom-a-y-Finanzas/Estados-Financieros-NIIF-Estado-de-Situaci-n-Finan/pfdp-zks5/about_data

- Demšar, J. et al. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research, 14*, 2349–2353. https://orangedatamining.com
- Orange Data Mining. Documentación de widgets y del complemento Text. https://orangedatamining.com/widget-catalog/
- Google. YouTube Data API v3: CommentThreads y Search. https://developers.google.com/youtube/v3/docs
- Blei, D., Ng, A. y Jordan, M. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research, 3*, 993–1022.
- Rousseeuw, P. (1987). Silhouettes: a graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65.
- Videos consultados: enlaces completos en la sección 4.3.
- Repositorio: https://github.com/Tayrun/Dinamica-Empresarial. Aplicación: https://dinamica-empresarial.onrender.com